

基于 BP 与 RBF 级联神经网络的日负荷预测

陈刚¹, 周杰¹, 张雪君¹, 张忠静²

(1. 输配电装备及系统安全与新技术国家重点实验室(重庆大学), 重庆市 沙坪坝区 400044;

2. 贵州电网公司 贵阳供电局, 贵州省 贵阳市 550002)

A Daily Load Forecasting Method Based on Cascaded Back Propagation and Radial Basis Function Neural Networks

CHEN Gang¹, ZHOU Jie¹, ZHANG Xue-jun¹, ZHANG Zhong-jing²

(1. State Key Laboratory of Power Transmission Equipment & System Security and New Technology

(Chongqing University), Shapingba District, Chongqing 400044, China;

2. Guiyang Power Supply Bureau, Guizhou Power Grid Corporation, Guiyang 550002, Guizhou Province, China)

ABSTRACT: Based on subsection forecasting and utilizing the advantages of back propagation (BP) neural network and radial basis function (RBF) neural network, such as short learning time of small-scale BP network and quick training of RBF network itself, a daily load forecasting method based on cascaded neural networks (CNN) is put forward. In this model non-load factors, i.e., weather factors, day styles and so on which affect the changes of daily load, and historical load factors are added into BP and RBF neural networks and considered separately, thus the forecasting model is simplified further. The results of calculation example show that the proposed model converges quicker and is more efficient than common CNN, the forecasting accuracy is evidently improved.

KEY WORDS: daily load forecast; back propagation (BP) neural network; radial basis function (RBF) neural network; cascaded neural network

摘要: 在采用分段预测方法的基础上, 利用小规模 BP(back propagation)神经网络学习时间短和径向基函数(radial basis function, RBF)神经网络自身训练速度快的优点, 提出了基于 BP 和 RBF 网络的级联神经网络日负荷预测模型, 将影响日负荷变化的非负荷因素(气象、日类型等)与历史负荷因素分别加入 BP 和 RBF 网络中分开考虑, 进一步简化了预测模型。计算实例表明, 该模型较一般级联神经网络模型收敛更快速、高效, 预测精度有了很大提高。

关键词: 日负荷预测; BP 神经网络; 径向基函数神经网络; 级联神经网络

0 引言

电力供需瞬时平衡的特点决定了其预测比其他行业更为关键, 做好电力负荷预测是实现电网安

全、经济运行的重要保障^[1]。随着电力市场的发展, 精度高、速度快的预测方法越来越受到重视^[2-6]。

近 10 多年来, 人工神经网络(artificial neural network, ANN)技术的快速发展使得基于人工神经网络的短期负荷预测方法受到了广泛关注^[7-9]。其中 BP(back propagation)网络和径向基函数(radial basis function, RBF)神经网络是目前最成熟、应用最广泛的人工神经网络。BP 网络具有多维非线性映射能力, 与其他方法相结合克服其易陷入局部极小点的缺陷后, 能取得满意的结果^[10-12]; RBF 网络具有可逼近任意非线性映射的能力^[13], 算法简单、实用, 取得了较好的效果^[14-17]。

由于影响短期负荷变化的因素很多, 单一神经网络拓扑结构往往非常复杂, 收敛较慢, 于是国内外学者提出建立级联神经网络模型来进行负荷预测。文献[18]提出一种级联神经网络模型, 预测结果表明此模型比传统神经网络模型精度更高。但由于没有将影响负荷变化的因素在前后级神经网络中分开考虑, 导致前后两级神经网络的拓扑结构都很复杂, 影响了预测速度。文献[19]提出的级联神经网络逐一预测一日 24 整点的负荷值, 从其前后级神经网络的输入、输出可以看出: 该级联神经网络虽然已将影响负荷变化的气象因素和历史负荷因素在前后级神经网络中分开考虑, 但其后级 RBF 网络的输入并没有利用前级 BP 网络的输出, 前后级之间缺乏级联联系, 很难将这种模型称为真正的级联神经网络模型; 另外前级 BP 网络只考虑到天

气因素, 如果将日类型和历史峰谷荷同时考虑进去, 并预测出预测日的负荷水平, 使后级 RBF 网络只考虑历史负荷因素, 这样前后级网络的预测目标会更加清晰, 整个预测模型的性能会更优。

本文在采用分段预测方法的基础上, 充分利用小规模 BP 网络学习时间短和 RBF 网络自身训练速度快的优点, 提出基于 BP 网络与 RBF 网络的级联神经网络预测模型, 将影响日负荷变化的非负荷因素(气象、日类型因素等)与历史负荷因素分别加入 BP 和 RBF 网络中分开考虑, 即 BP 网络只考虑气象、日类型等非负荷因素的影响, 而 RBF 网络只考虑历史负荷因素的影响。因此, 大大简化了 BP 和 RBF 网络的拓扑结构, 在取得满意的预测精度的前提下, 整个预测过程的运算速度也大大提高。

1 BP-RBF 级联神经网络

BP 网络采用多层结构, 包括输入层、一个或多个隐含层和输出层, 可实现从输入到输出的任意复杂的非线性映射关系, 并具有良好的泛化能力, 能完成复杂模式识别和函数拟合等任务。

RBF 网络是具有单隐含层的 3 层前馈型神经网络, 目前已经证明, RBF 网络能以任意精度逼近任意的连续函数^[20]。其基本思想是: 用 RBF 作为隐单元的“基”, 构成隐含层空间, 隐含层对输入矢量进行变换, 将低维的模式输入数据变换到高维空间, 使得在低维空间中的线性不可分问题在高维空间中线性可分^[21]。

BP 网络具有很强的非线性拟合能力, 尤其是对预测中天气、温度等因素处理方便, 而且学习规则简单, 便于计算机实现^[22]。RBF 网络隐含层 RBF 函数的实质是对输入信息聚类特征的提取, 更适用于输入量为同一类信息时的非线性映射。

BP 网络的缺点是需要大量的学习样本, 固有的训练效率低, 而且易陷入局部极小点^[11]。而 RBF 网络由隐含层到输出层的映射是线性的, 可大大加快学习速度, 避免陷入局部最优。

本文充分利用这 2 种神经网络的优点, 提出了基于 BP 和 RBF 级联神经网络的预测模型。不但克服了 BP 网络训练效率低的缺点, 而且充分利用了 RBF 网络训练速度快和不会陷入局部最优的优点。

本文确定 BP 网络作为级联神经网络的前级网络, 而 RBF 网络为后级网络。基于以下考虑:

1) 对 2 个具有相同输入、输出数目以及隐含节点数的 BP 和 RBF 网络(如图 1 所示), BP 网络有




图 1 含 5 个隐节点的 BP 与 RBF 网络

Fig. 1 The BP and RBF network including 5 hidden nodes

10 个权值需要调整, 而 RBF 网络仅有 5 个。BP 网络训练的复杂度为 $10N$, RBF 网络训练的复杂度为 $5N$, 其中 N 为训练样本数。可见, 随着隐含节点数的增加, BP 网络的训练复杂度将大大超过 RBF 网络。因此使 BP 网络只考虑输入量较少的非负荷因素, 减小其规模和训练复杂度, 而输入量较多的历史负荷因素则加入 RBF 网络。

2) RBF 与 BP 网络相比, 具有更好的函数逼近能力, 可用于对任意函数的逼近, 且可处理系统内在的难以解析的规律性, 具有更短的学习时间和更快的学习收敛速度。

本文先针对图 1 中的 BP 和 RBF 网络, 测试其函数逼近能力。考虑如下理想函数:

$$f_s(x) = \sqrt{x} \quad (1)$$

样本集选取 51 个点, x 由 0 至 5 每隔 0.1 取一点, 同时在 f 上加 $\pm 8\%$ 以内的噪声。计算 2 个网络输出 $f_r(x)$ 和无噪声输出 $f_s(x)$ 的均方差(mean square error, MSE)。2 者的训练方法都采用梯度下降法, 训练循环次数都为 100 次。训练后, BP 网络的 MSE 为 3.904 6%, RBF 网络为 0.232 2%, 可见训练次数较少时, RBF 网络比 BP 网络有更好的逼近能力, 因此 RBF 网络更适合考虑具有很强规律性的历史负荷因素。

2 预测模型及算法

从目前已有的国内外短期负荷预测的 ANN 模型来看, 一次性给出 24 点的负荷预测通常要比分段预测误差大^[23]。采用分段预测方法时, 输入变量数会减少, 隐含层的神经元个数也会减少, 因此, 网络的训练和学习时间都会变短, 收敛速度也会加快, 从而可提高模型的运行效率, 为此, 本文采用分段预测方法。

日负荷预测的级联神经网络结构如图 2 所示。

1) BP 网络的输入变量为非负荷因素(气象、日类型因素等)和历史峰谷荷, 输出变量为预测日的峰谷荷, 即用 BP 网络大致给出预测日的负荷水平。由




图2 级联神经网络负荷预测模型
Fig. 2 The load forecasting model of cascaded neural network

于它是一个小规模的神经网络,训练速度很快,克服了BP网络训练效率低的缺点;2)RBF网络接收BP网络的输出(预测日峰谷荷)作为输入,再加上历史负荷值,进行日负荷预测,充分利用RBF网络适用于输入量为同一类信息的特点。BP、RBF子网络各司其职,协调工作,既提高了模型的效率,又使得不同的负荷影响因素在相对公平的条件下对负荷预测值产生影响,避免了因输入量值域范围的较大差异而导致某些影响因素在总体映射效果中被歪曲甚至淹没现象的发生。

级联神经网络训练流程如图3所示,下面分别介绍BP和RBF网络的训练算法。

BP算法用于BP网络的权值和阈值学习,步骤如下:

- 1) 权值和阈值初始化。
- 2) 给定输入 x_k 和目标输出 y_k 。

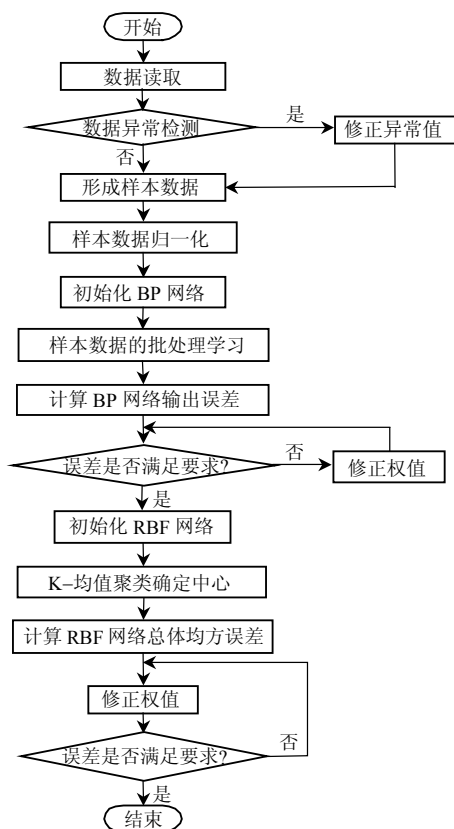


图3 级联神经网络训练流程

Fig. 3 The training process of cascaded neural network

3) 计算实际输出 \hat{y}_k (正向过程)。

4) 修正权值(反向过程):从输出层开始,误差信号沿连接通路反向传播,通过修正各权值,使误差最小:

$$w_{ij}^l = w_{ij}^l - \eta \frac{\partial E_k}{\partial w_{ij}^l} = w_{ij}^l - \eta \delta_{ik}^l O_{jk}^{l-1} \quad (2)$$

式中: w_{ij}^l 为第 l 层第 j 个神经元到第 $l+1$ 层第 i 个神经元的权系数; E_k 为 k 模式的总误差; η 为增益项; δ_{ik}^l 为第 l 层 i 节点 k 模式的误差项; O_{jk}^{l-1} 为第 l 层 j 节点 k 模式的输入项。若 i 为输出节点,则有

$$\delta_{ik}^l = -\hat{y}_k(1 - \hat{y}_k)(y_k - \hat{y}_k) \quad (3)$$

若 i 为隐节点,则有

$$\delta_{ik}^l = O_{ik}^l(1 - O_{ik}^l) \sum_m \delta_{mk}^{l+1} w_{mi}^{l+1} \quad (4)$$

5) 若达到误差精度要求,则输出结果,否则返回步骤3)。

RBF网络要学习的参数有3个,步骤如下:

1) 学习中心 $t_i (i=1,2,\dots,I, I$ 为隐单元的个数)。自组织学习过程要用到聚类算法,常用K-均值聚类算法。

2) 确定方差 $\sigma_i (i=1,2,\dots,I)$ 。当RBF选用高斯函数时,即

$$G(\|x_k - t_i\|) = \exp\left(-\frac{1}{2} \sum_{i=1}^I \frac{\|x_k - t_i\|^2}{\sigma_i^2}\right), \quad i=1,2,\dots,I$$

方差可用式(5)计算

$$\sigma_1 = \sigma_2 = \dots = \sigma_I = d_{\max} / \sqrt{2I} \quad (5)$$

式中 d_{\max} 为所选取中心之间的最大距离。

3) 学习权值 $w_{ij} (i=1,2,\dots,I; j=1,2,\dots,J)$ 。权值的学习可采用最小均方(least mean square, LMS)算法。RBF网络的实际输出为

$$Y(n) = G(n)W(n) \quad (6)$$

其中

$$Y(n) = [y_{kj}(n)], \quad k=1,2,\dots,N; j=1,2,\dots,J \quad (7)$$

式中: y_{kj} 为RBF网络输出层第 k 个神经元的输出值; N 为RBF网络输出层的神经元数; J 为RBF网络隐含层的神经元数。

3 算例分析

以某地区电网为例,系统平均负荷约为1.6GW。从2003—2006年月平均日负荷率的变化情况来看,该地区总体负荷率较高,均在94%左右,主要由于大工业负荷比重较大,第三产业和居民生活用电负荷受气象、日类型等因素影响较大。2003—2006年典型日负荷曲线如图4所示。




图 4 2003—2006 年典型日负荷曲线
Fig. 4 The typical daily load curves from 2003 to 2006

由图 4 可见，该地区日负荷曲线具有周期规律性，一般每日出现 2 个谷荷点，分别为 8 时和 16 时，它将日负荷曲线分为极为相似的 3 段。因此分段预测中本文采用分 3 段预测，建立 3 个结构相同的 RBF 网络，每个 RBF 网络分别预测连续 8 个整点时刻的负荷值，3 个 RBF 网络并列同时工作，刚好预测出每日 24 个整点的负荷值，3 个 RBF 网络的结构同为 18+18+8，其中输入为：前级 BP 网络的 2 个输出；预测日前 1 日、前 2 日连续 8 个同时刻的负荷值。输出为此连续 8 个时刻的负荷值。BP 网络的结构为 10+10+2，其中输入为：预测日前 1 日、前 2 日的峰谷荷及最高、最低气温；预测日前 1 日和预测日的日类型。输出为预测日预测峰谷荷。

采用本文提出的级联神经网络模型和文献[19]中的网络模型同时对 2006 年 7 月 26 日的 24 个整点负荷值进行预测，结果见表 1，对比结果见表 2，

表 1 负荷预测结果
Tab. 1 The load forecasting results

时刻	实际值/ MW	预测值/ MW	相对 误差/%	时刻	实际值/ MW	预测值/ MW	相对 误差/%
00:00	1567.24	1507.38	3.82	12:00	1439.24	1498.91	4.15
01:00	1646.23	1587.81	3.55	13:00	1511.1	1467.76	2.87
02:00	1664.42	1620.19	2.66	14:00	1446.69	1401.16	3.15
03:00	1689.59	1658.05	1.87	15:00	1455.46	1415.37	2.75
04:00	1671.29	1708.54	2.23	16:00	1320.33	1354.7	2.6
05:00	1656.05	1714.39	3.52	17:00	1414.91	1378.23	2.59
06:00	1652	1679.73	1.68	18:00	1347.65	1397.2	3.68
07:00	1649.24	1620.14	1.76	19:00	1373.72	1413.51	2.9
08:00	1473.55	1522.88	3.38	20:00	1396.4	1447.3	3.65
09:00	1535.96	1594.28	3.8	21:00	1413.28	1451.28	2.69
10:00	1504.92	1568.16	4.2	22:00	1385.36	1421.9	2.64
11:00	1501.53	1557.46	3.72	23:00	1439.1	1498.26	4.11

表 2 预测结果对比
Tab. 2 The contrast of forecasting results

统计项目	本文方法	文献[19]中方法
相对误差小于 2% 的点数	3	3
相对误差介于 2%~3% 的点数	9	6
相对误差介于 3%~4% 的点数	9	10
相对误差超过 4% 的点数	3	5
最大相对误差/%	4.20	4.65
最小相对误差/%	1.68	1.84
平均相对误差/%	3.08	3.36

可见本文预测模型精度更高。并且由于本文采用分段预测方式，3 个 RBF 网络同时工作，与文献[19]中采用的逐一预测方式(即逐小时预测)相比，预测速度更快，效率更高。

4 结论

本文提出的基于 BP 与 RBF 的级联神经网络日负荷预测模型，将非负荷因素和时间序列负荷因素分别加入 BP 和 RBF 网络中分开考虑，使 BP 和 RBF 网络的拓扑结构都得到了简化。对某地区电网进行的日负荷预测结果表明，本文提出的方法具有更高的预测精度和更快的预测速度，具有较强的实用价值。

参考文献

[1] 康重庆，夏清，刘敏. 电力系统负荷预测[M]. 北京：中国电力出版社，2007：4.

[2] 赵登福，王蒙，张讲社，等. 基于确定性退火方法的短期负荷预测[J]. 中国电机工程学报，2001，21(7)：1-4.

Zhao Dengfu, Wang Meng, Zhang Jianshe, et al. A deterministic annealing approach for short term load forecasting[J]. Proceedings of the CSEE, 2001, 21(7): 1-4(in Chinese).

[3] 赵登福，王蒙，张讲社，等. 基于支撑向量机方法的短期负荷预测[J]. 中国电机工程学报，2002，22(4)：26-30.

Zhao Dengfu, Wang Meng, Zhang Jianshe, et al. A support vector machine approach for short term load forecasting[J]. Proceedings of the CSEE, 2002, 22(4): 26-30(in Chinese).

[4] 陶文斌，张粒子，潘弘，等. 基于双层贝叶斯分类的空间负荷预测[J]. 中国电机工程学报，2007，27(7)：13-17.

Tao Wenbin, Zhang Lizi, Pan Hong, et al. Spatial electric load forecasting based on double-level Bayesian classification [J]. Proceedings of the CSEE, 2007, 27(7): 13-17(in Chinese).

[5] 张林，刘先珊，阴和俊. 基于时间序列的支持向量机在负荷预测中的应用[J]. 电网技术，2004，28(10)：38-41.

Zhang Lin, Liu Xianshan, Yin Hejun. Application of support vector machines based on time sequence in power system load forecasting [J]. Power System Technology, 2004, 28(10): 38-41(in Chinese).

[6] 康重庆，周安石，王鹏，等. 短期负荷预测中实时气象因素的影响分析及其处理策略[J]. 电网技术，2006，30(7)：5-10.

Kang Chongqing, Zhou Anshi, Wang Peng, et al. Impact analysis of hourly weather factors in short-term load forecasting and its processing strategy[J]. Power System Technology, 2006, 30(7):

- 5-10(in Chinese).
- [7] 牛东晓, 曹树华, 赵磊, 等. 电力负荷预测技术及其应用[M]. 北京: 中国电力出版社, 1998: 199.
- [8] 姚孝孝, 姚金雄, 李宝庆, 等. 基于竞争分类的神经网络短期电力负荷预测[J]. 电网技术, 2004, 28(10): 45-48.
Yao Lixiao, Yao Jinxiong, Li Baoqing, et al. Short-time load forecasting using neural network based on competitive classification [J]. Power System Technology, 2004, 28(10): 45-48(in Chinese).
- [9] 于海燕, 张凤玲. 基于模糊神经网络的电力负荷短期预测[J]. 电网技术, 2007, 31(3): 68-72.
Yu Haiyan, Zhang Fengling. Short-term load forecasting based on fuzzy neural network[J]. Power System Technology, 2007, 31(3): 68-72(in Chinese).
- [10] Liang Haifeng, Li Gengyin, Zhou Ming. An adaptive BP-network approach to short term load forecasting[C]. Proceedings of 2004 IEEE International Conference on Electric Utility Deregulation, Restructuring and Power Technologies, Hong Kong, 2004.
- [11] 姚孝孝, 宋玲芳, 李庆宇, 等. 基于模糊聚类分析与 BP 网络的电力系统短期负荷预测[J]. 电网技术, 2005, 29(1): 20-23.
Yao Lixiao, Song Lingfang, Li Qingyu, et al. Power system short-term load forecasting based on fuzzy clustering analysis and BP neural network[J]. Power System Technology, 2005, 29(1): 20-23(in Chinese).
- [12] Sun Wei, Zou Ying. Short term load forecasting based on BP neural network training by PSO[C]. Proceedings of IEEE the Sixth International Conference on Machine Learning and Cybernetics, Hong Kong, 2007.
- [13] Park J, Sandberg I W. Approximation and radial-basis-function network[J]. Neural Computation, 1993, 5(2): 305-316.
- [14] Gontar Z, Hatzigargyion N. Short term load forecasting with radial basis function network[C]. 2001 IEEE Porto Power Tech Conference, Porto, Portugal, 2001.
- [15] 雷绍兰, 孙才新, 周淦, 等. 基于径向基神经网络和自适应神经网络系统的电力短期负荷预测方法[J]. 中国电机工程学报, 2005, 25(22): 78-82.
Lei Shaolan, Sun Caixin, Zhou Quan, et al. Short-term load forecasting method based on RBF neural network and Anfis system [J]. Proceedings of the CSEE, 2005, 25(22): 78-82(in Chinese).
- [16] 吴宏晓, 侯志俭, 刘涌, 等. 基于免疫聚类径向基函数网络模型的短期负荷预测[J]. 中国电机工程学报, 2005, 25(16): 53-56.
Wu Hongxiao, Hou Zhijian, Liu Yong, et al. A short-term load forecasting approach based on immune clustering RBF network model[J]. Proceedings of the CSEE, 2005, 25(16): 53-56(in Chinese).
- [17] Zhu Youchan, He Yujun. Short-term load forecasting model using fuzzy C means based radial basis function network[C]. Proceedings of the IEEE Sixth International Conference on Intelligent Systems Design and Applications, 2006.
- [18] AlFuhaid A S, El-Sayed M A, Mahmoud M S. Cascaded artificial neural networks for short-term load forecasting[J]. IEEE Trans on Power Systems, 1997, 12(4): 1524-1529.
- [19] 金海峰, 熊信良, 吴耀武. 基于级联神经网络的短期负荷预测方法[J]. 电网技术, 2002, 26(3): 49-51.
Jin Haifeng, Xiong Xinyin, Wu Yaowu. A short-term load forecasting method based on cascade neural network[J]. Power System Technology, 2002, 26(3): 49-51(in Chinese).
- [20] 高山, 单渊达. 基于径向基函数网络的短期负荷预测[J]. 电力系统自动化, 1999, 23(5): 31-34.
Gao Shan, Shan Yuanda. A short-term forecasting method based on radial basis function network[J]. Automation of Electric Power Systems, 1999, 23(5): 31-34(in Chinese).
- [21] 高隽. 人工神经网络原理及仿真实例[M]. 北京: 机械工业出版社, 2003: 56-57.
- [22] 周佃民, 管晓宏, 孙婕, 等. 基于神经网络的电力系统短期负荷预测研究[J]. 电网技术, 2002, 26(2): 10-13.
Zhou Dianmin, Guan Xiaohong, Sun Jie, et al. A short-term forecasting system based on BP artificial neural network[J]. Power System Technology, 2002, 26(2): 10-13(in Chinese).
- [23] 李振然, 贾旭彩. 基于人工神经网络的短期负荷预测[J]. 广西电力, 2002(4): 7-10.
Li Zhenran, Jia Xucai. Short-term load forecasting based on artificial neural network[J]. Guangxi Electric Power, 2002(4): 7-10(in Chinese).



陈刚

收稿日期: 2009-02-18.

作者简介:

陈刚(1964—), 男, 副研究员, 硕士生导师, 主要从事电力系统运行与控制、微机在电力系统中的应用、电力 MIS 系统及负荷预测方面的研究;

周杰(1984—), 男, 硕士研究生, 从事电力系统及其自动化、负荷预测方面的研究, E-mail: jack2034.student@sina.com;

张雪君(1982—), 女, 硕士研究生, 从事电力系统及其自动化、负荷预测方面的研究;

张忠静(1979—), 女, 硕士, 主要从事电力系统运行与控制、变电管理、电网规划方面的研究。

(责任编辑 沈杰)

华中电网率先试行水电应急交易办法

2009年5月20日, 国家电监会华中电监局向区域内电力企业发布实施《华中区域水电减弃增发应急交易暂行办法》, 标志着一种崭新的水电应急交易机制率先试水华中电网。《办法》的主要思想是充分利用华中的水能资源、发挥省间(或重要断面)输电通道能力, 通过建立水电应急交易机制, 促使部分省(市)的富余水电在全区范围内得到及时、高效的利用。《办法》中所界定的水电应急交易为在特定时期内(水电主汛期或非汛期但面临弃水时)区域内一个或几个省(市)水电电量无法全部在本省(市)内消化, 需纳入区域内其他省(市)消纳而开展的省(市)间短期临时电量交易; 其水电应急交易采取自愿协商的市场方式和按负荷比例分摊方式。华中地区的能源资源分布具有“南水、北火、西水气”的特点, 在电网的整体运行格局上呈现“南北水火互济、东西丰枯调剂”的局面, 这使得华中电网具有在区域内进行大范围电力资源调剂的客观优势和潜力。截至2008年底, 华中地区统调总装机容量达1.44亿kW, 其中水、火电比重分别约占40%、60%。充分利用好华中区域的水能资源, 让水电在汛期大发时尽量不弃水或少弃水, 对华中地区建设节能型社会有着重要意义。